

Proyecto · Entrega 1

Reservas y satisfacción en CupiTaller

MINE-4214 Modelado y Diseño de Datos
Universidad de los Andes · Octubre de 2026

Integrantes: *María Alejandra Pérez Petro, Santiago Martínez Novoa*

Índice

1. Objetivo y análisis requeridos	2
1.1. Organización y dependencia	2
1.2. Proceso que genera los datos	3
1.3. Reglas de negocio adoptadas	4
1.4. Análisis 1 · Inasistencia y presión de cola	4
1.5. Análisis 2 · Satisfacción con las tutorías	6
1.6. Caracterización general de los datos	9
1.7. Información disponible y relaciones entre las fuentes	9
2. Ecosistema de analítica	10
2.1. Pertinencia del ecosistema	11
3. Exploración y calidad de datos	12
3.1. Estadísticas descriptivas	12
3.2. Completitud	13
3.3. Unicidad	13
3.4. Consistencia	13
3.5. Validez	14
3.6. Transformaciones que se derivan del análisis de calidad	14
4. Modelo de datos conceptual	15
4.1. Procesos de negocio y granularidad	15
4.2. Modelos dimensionales propuestos	16
4.3. Matriz de bus	18
4.4. Decisiones de diseño y su justificación	18
4.5. Criterios de calidad del modelo	20
4.6. Historia de atributos (SCD)	20
4.7. Diseño del repositorio	21
5. Transformación Silver → Gold	22
5.1. Entradas y reglas de la transformación	22
5.2. Diseño del proceso	23

5.3. Decisiones importantes	23
5.4. Mecanismo de validación y resultados	24
5.5. Correcciones que debería hacer el responsable de la fuente	25
6. Respuesta a los análisis	25
6.1. Análisis 1 · Inasistencia y presión de cola	26
6.2. Análisis 2 · Satisfacción	27
6.3. Por qué el modelo es adecuado para estos análisis	28
6.4. Usuarios y funcionalidad del tablero	28
7. Gestión del proyecto	29
7.1. Contribuciones y distribución de puntos	29
7.2. Uso de inteligencia artificial generativa	29

1. Objetivo y análisis requeridos

1.1. Organización y dependencia

La **Universidad de los Andes** es una universidad privada de Bogotá, Colombia. Su **Departamento de Ingeniería de Sistemas y Computación** (DISC), dentro de la Facultad de Ingeniería, ofrece el servicio de tutorías **CupiTaller** para los cursos de programación de los primeros semestres:

- **Introducción a la Programación** (código ISIS-1221, abreviado **IP**).
- **APO 1** y **APO 2**, cursos de programación que IP reemplazó. Aparecen en los datos históricos.
- **Estructuras de Datos y Algoritmos (EDA)**.
- **Diseño y Programación Orientada a Objetos (DPOO)**.

En CupiTaller, **monitores** (estudiantes que actúan como tutores de sus compañeros) atienden sesiones con cita previa. Hay tres **modalidades** de tutoría:

- **Normal**: dura 50 a 60 minutos.
- **Express**: dura 20 a 30 minutos y sirve para dudas puntuales.
- **Normal pico**: es una sesión Normal en las semanas de más demanda.

Las citas se gestionan en **Bookeau**, la plataforma web de reservas. El estudiante pide una franja horaria. Si no hay cupo, queda **en cola**, es decir, en lista de espera, y no recibe cita. Cada cita termina en uno de estos **estados**:

- **Atendida**: la tutoría se dio. Bookeau la registra como «Finalizada» o «Realizada», dos etiquetas que el proyecto trata como una sola (ver las reglas de negocio en la sección 1.3).
- **Cancelada**: el estudiante canceló. Puede ser a tiempo, con excusa, por sanción, o tarde y sancionada. Una **sanción** es una penalización por incumplir las reglas de reserva.

- **No asistió:** el estudiante no se presentó.

Antes de la cita, el estudiante responde una **encuesta previa** (objetivo de la sesión y aceptación de condiciones). Después, responde una **encuesta de satisfacción** con una calificación de 1 a 5 al tutor y comentarios abiertos.

Trabajamos con dos áreas del DISC. La **coordinación de CupiTaller** planea las franjas y asigna monitores cada semestre. La **coordinación académica de los cursos** se encarga de la formación de los monitores.

1.2. Proceso que genera los datos

Los dos análisis usan datos que nacen de un mismo proceso: el ciclo de una tutoría en Bookeau. La tabla indica, paso a paso, quién actúa, qué ocurre y qué dato queda registrado. Los nombres entre comillas son los de las columnas tal como vienen de Bookeau.

Paso	Quién actúa	Qué ocurre	Dato que queda registrado	Fuente (archivo)
1	Estudiante	Elige curso (servicio), modalidad y una franja horaria, y pide la cita.	Un evento de reserva con su «ID», «Fecha inicio», «Fecha fin», «Servicio», «Tipo de horario», «Categoría», «Prioritaria», y los datos del usuario («Código usuario», «Programa», «Tipo de usuario»).	Reservas
2	Estudiante	Antes de confirmar, responde la encuesta previa: para qué usará la tutoría y si acepta las condiciones (no usar el celular, tener una solución probada si trabaja en una tarea, términos de uso).	Cuatro respuestas por reserva, ligadas a su «ID».	Encuesta Reserva Express / Normal IP
3	Bookeau	Si hay cupo en la franja, la reserva queda hecha. Si no, queda en cola .	«Estado de la reserva»: Reservada o En cola. Existe también la etiqueta «Cola cancelada por reservación», cuyo significado exacto no está documentado; la tratamos como una solicitud en cola que se cerró.	Reservas
4	Estudiante	Puede cancelar antes de la cita.	«Estado de la reserva»: Cancelada a tiempo, con excusa, por sanción, o tarde y sancionada.	Reservas
5	Estudiante y monitor	El día de la cita, el estudiante llega (o no) y un monitor lo atiende.	«Fecha de llegada» (solo si llegó) y «Prestador del servicio», que es el monitor asignado.	Reservas
6	Monitor o sistema	La cita se cierra con un estado final: Finalizada o Realizada (atendida), o No asistió.	«Estado de la reserva» final.	Reservas

Paso	Quién actúa	Qué ocurre	Dato que queda registrado	Fuente (archivo)
7	Estudiante	Después de la cita, responde de forma voluntaria la encuesta de satisfacción: calificación de la ayuda del tutor (1 a 5), preguntas sobre la tutoría y comentarios escritos.	Respuestas ligadas al «ID», con un «Estado» de validez (Válida o Inválida) asignado por Bookeau.	Encuesta Express / Normal

1.3. Reglas de negocio adoptadas

Para analizar los datos el proyecto aplica cuatro reglas. Se definen aquí y el resto del informe se refiere a ellas por su código. Dos las aportó o confirmó la coordinación de CupiTaller y dos son decisiones del equipo. **Silver** es la capa de datos ya limpios y **Gold** es la base de datos final para el análisis (ambas se explican en la sección 2).

Regla	Qué establece	Origen	Cómo se conserva el dato original
R01	Las reservas en estado «Finalizada» y «Realizada» se tratan como un solo estado de análisis, <i>Atendida</i> .	Aportada por la coordinación	El estado original se conserva en una columna aparte.
R02	Las encuestas que Bookeau marca como «Inválida» (166 en total) se excluyen de los análisis y de los indicadores de respuestas. Su reserva sí se mantiene.	Sugerida por el equipo, aprobada por la coordinación	Permanecen en Silver para auditoría.
R03	Para los análisis de Gold solo se incluyen los ID asociados a reservas de tutorías, es decir, las de tipo de horario Normal, Express o Normal pico. Se excluyen las entrevistas, las salas y las etiquetas históricas, junto con las encuestas de esas reservas.	Aportada por la coordinación	Permanecen en Silver.
R04	Una solicitud en cola no ocupa cupo. Por eso la inasistencia se mide solo sobre las citas que llegaron a su hora: No asistió / (Atendida + No asistió).	Aportada por la coordinación	Los estados originales se conservan; el grupo de estado es un atributo adicional.

1.4. Análisis 1 · Inasistencia y presión de cola

Elemento	Definición
Objetivo	Identificar en qué modalidades, días, horas y períodos los estudiantes reservan y no asisten, y en cuáles se quedan sin cupo, para decidir dónde reforzar franjas (más monitores) y dónde aplicar medidas contra la inasistencia (recordatorios, política de sanciones).
Destinatario	Coordinación de CupiTaller.

Elemento	Definición
Por qué ese rol	Planea las franjas y asigna monitores cada semestre y fija las reglas de reserva y de sanción. Las dos decisiones que este análisis apoya (cuántos monitores poner en cada franja y qué reglas ajustar) son exactamente las suyas.
Cómo lo usaría	Antes de cada semestre, revisa por modalidad, día y hora qué proporción de citas se pierde y dónde se acumula la cola; cambia la oferta de franjas o las reglas según lo que encuentre.
Preguntas	(1) ¿Cómo evolucionan las reservas y la atención por período? (2) ¿Qué modalidades, días y horas tienen mayor tasa de inasistencia? (3) ¿Qué proporción de solicitudes termina en cola y dónde?
Indicadores	Evento de reserva: una fila de Reservas. Atención: reserva en estado Atendida. Tasa de inasistencia = No asistió / (Atendida + No asistió). Proporción en cola = (En cola + Cola cancelada por reservación) / eventos. Proporción de cancelaciones = canceladas / eventos.
Preguntas complementarias	(4) Una vez confirmados los estados y la población elegible: ¿qué proporción de los eventos elegibles se atiende, se cancela o termina sin asistencia?
Viabilidad	Los datos cubren casi diez años (29 períodos) y 86.562 eventos. Todas las variables necesarias están en un solo archivo (Reservas), sin cruces con otras fuentes.

Datos del Análisis 1

- **Fuente:** archivo *Reservas*, 29 archivos de Excel (uno por período, de 201620 a 202610), con 86.562 filas y 17 variables.
- **Nivel de detalle (granularidad):** una fila es un **evento de reserva**: una solicitud de un estudiante para una franja, sin importar cómo terminó (atendida, cancelada, no asistió o en cola). El dato más fino es el minuto de inicio de la cita.
- **Período cubierto:** 19 de agosto de 2016 a 22 de mayo de 2026.

Variable clave	Qué significa	Valores y tipo	Para qué se usa
ID	Identificador del evento de reserva	Texto, único (86.562 valores)	Contar eventos y vincular las encuestas
Estado de la reserva	Cómo terminó la solicitud	12 etiquetas (Finalizada, Cancelada a tiempo, En cola, No asistió, Realizada, etc.)	Calcular atención, inasistencia, cola y cancelaciones
Tipo de horario	Modalidad de la tutoría	10 etiquetas (Normal, Express, Normal pico y otras históricas)	Comparar modalidades
Servicio	Curso para el que se pide la tutoría	11 etiquetas (IP, APO 1, EDA, APO 2...)	Comparar cursos
Fecha inicio y Fecha fin	Inicio y fin programados de la cita	Fecha y hora	Día de la semana, hora, período; duración programada (mínimo 20, mediana 50, máximo 120 minutos)

Variable clave	Qué significa	Valores y tipo	Para qué se usa
Fecha de llegada	Momento en que el estudiante llegó	Fecha y hora; vacía en 50,2 % (cancelaciones y cola no llegan)	Revisar la coherencia del estado (3.4)
Prestador del servicio	Monitor asignado	Texto; vacío en 49,2 % (solo las citas atendidas tienen monitor)	Apoyar la asignación de monitores por franja
Prioritaria	Indicador sí/no de reserva prioritaria	Catógorica	Medida del modelo (4.1)
Programa	Programa académico del estudiante	Texto libre, 213 variantes	Segmentar por programa, ya normalizado
Período	Semestre de la reserva	Código de seis cifras, 29 valores; se deduce del nombre del archivo	Evolución en el tiempo

Indicadores del Análisis 1.

Indicador	Definición	Denominador o población
Eventos de reserva	Conteo de ID distintos en el segmento	Todos los eventos de la selección, incluidos cola y cancelaciones
Distribución de estados	Eventos con cada etiqueta literal	Todos los eventos del mismo segmento
Agenda por día y hora	Eventos por día ISO y hora de «Fecha inicio»	Eventos con inicio disponible
Minutos programados	Fin programado menos inicio programado	Eventos con ambos campos coherentes
Tasa de asistencia	Finalizada o Realizada / eventos elegibles	Numerador agrupado por R01; población elegible por confirmar
Tasa de inasistencia	No asistió / (Atendida + No asistió)	Regla R04: la cola no ocupa cupo
Tasa de cancelación	Eventos cancelados / población definida	Falta definir si entra la cancelación de cola y la cancelación por sanción

La población de Reservas incluye modalidades distintas de la tutoría (entrevistas, salas y etiquetas históricas); por la regla R03, los análisis de Gold solo usan las reservas de tutorías. Con los datos recibidos, las modalidades Normal, Express y Normal pico suman 83.894 de las 86.562 reservas (96,9 %), por lo que el volumen sigue dentro del rango de 80.000 a 200.000 registros que pide la guía. Para comparar Express con Normal se usan las etiquetas exactas, y «Normal pico» permanece separada hasta justificar su equivalencia.

Otras columnas de Reservas (nombre, correo y código del usuario, tipo de usuario, categoría, códigos de servicio) identifican personas o duplican información. No se usan en el análisis, y el modelo no incluye una dimensión de personas para no exponer datos personales.

1.5. Análisis 2 · Satisfacción con las tutorías

Elemento	Definición
Objetivo	Conocer cómo califican los estudiantes la ayuda del tutor y en qué servicios, modalidades y períodos se concentran las calificaciones bajas, para decidir qué priorizar en la formación y el seguimiento de los monitores.
Destinatario	Coordinación académica de los cursos.
Por qué ese rol	Es quien forma y evalúa a los monitores. Una calificación baja concentrada en un curso, una modalidad o un semestre le dice dónde reforzar la formación.
Cómo lo usaría	Cada semestre revisa la proporción de calificaciones bajas por segmento, compara con los semestres anteriores y decide dónde intervenir (capacitación, acompañamiento, ajustes a la modalidad).
Preguntas	(1) ¿Cómo se distribuye la calificación del tutor? (2) ¿Qué segmentos concentran calificaciones bajas (1 a 3)? (3) ¿Cómo cambian en el tiempo?
Indicadores	Encuestas válidas: las no marcadas «Inválida». Compleitud del ítem: parte de las encuestas válidas que contestó la calificación. Proporción de calificaciones 1 a 3 (indicador principal). Media y distribución de 1 a 5 (apoyo).
Preguntas complementarias	(4) ¿Qué porcentaje de las respuestas incluidas tiene una calificación utilizable? (5) ¿Cómo se comparan Express y Normal dentro de períodos y servicios con respuestas de ambas? (6) ¿Qué percepciones y temas aparecen en los comentarios? (esta última se desarrollará en las siguientes entregas)
Viabilidad	Hay 23.138 encuestas posteriores, todas vinculadas a su reserva por el ID, de modo que cada calificación se puede ubicar por curso, modalidad, período y programa.

Por qué el indicador principal es la proporción de 1 a 3. La escala tiene **efecto techo**: casi todas las notas son 5 (81,7 %, y la mediana es 5). El promedio apenas distingue entre grupos, mientras que la cola de notas bajas sí lo hace.

Datos del Análisis 2

- **Fuentes:** *Encuesta Express* (6.759 filas × 33 variables) y *Encuesta Normal* (16.379 filas × 35 variables), 29 archivos cada una. Para segmentar se cruzan por el ID con *Reservas* (fuente del Análisis 1). Todas las encuestas encuentran su reserva.
- **Nivel de detalle:** una fila es una **encuesta de satisfacción de una reserva**; en el modelo se desglosa además en una fila por pregunta contestada (384.792 respuestas contando también las encuestas previas).
- **Período cubierto:** de 201620 a 202610. Los formularios cambiaron en el tiempo, así que no todas las preguntas existen en todos los períodos.

Variable clave	Qué significa	Valores y tipo	Cobertura
ID	Identificador de la reserva a la que corresponde	Texto; vincula con Reservas	100 %

Variable clave	Qué significa	Valores y tipo	Cobertura
Califique la ayuda que le dio su tutor	Calificación del tutor	Entero de 1 a 5	Desde 201819; falta en 26,3 % (Express) y 30,9 % (Normal)
Estado	Validez de la encuesta según Bookeau	Válida o Inválida	100 %; 166 inválidas
Preguntas de aspectos del tutor (explicó, aclaró conceptos, fue receptivo, expresó con claridad...)	Valoración de la sesión	Escala de acuerdo (categorías)	Varía por pregunta y período
¿El tutor usó herramientas de inteligencia artificial?	Uso de IA en la tutoría	Categórica	Desde 2021 (Normal) y 2022 (Express); falta entre 60 % y 63 %
Comprensión del tema y material del curso	Autoevaluación del estudiante	Categórica	Falta en 72 % a 73 % (preguntas recientes)
Comentario sobre aspectos positivos y negativos del tutor	Texto libre	Texto	Presente en 76 % a 81 %; se analizará en la siguiente entrega
Servicio, Tipo de horario, Estado de la reserva, Programa y período	Datos de la reserva a la que pertenece la encuesta	Igual que en Reservas	100 %

Indicadores del Análisis 2

Indicador	Definición	Denominador o población
Calificaciones utilizables	Encuestas «Válida» con calificación entera de 1 a 5	Encuestas «Válida» del segmento (regla R02)
Distribución 1 a 5	Cantidad de cada calificación / calificaciones utilizables	Calificaciones utilizables del segmento
Mediana y media	Resumen de la calificación utilizable	Calificaciones utilizables, con su n
Complejidad del ítem	Calificaciones utilizables / encuestas válidas	Encuestas válidas del segmento
Tasa de respuesta	Reservas elegibles con respuesta / reservas elegibles	Falta definir invitación, elegibilidad, estados y períodos del instrumento
Comparación Express y Normal	Comparar dentro del mismo período y servicio original	Etiquetas exactas Express y Normal con calificación en ambas

Las encuestas «Inválida» se excluyen de numeradores y denominadores (regla R02) pero se cuentan en la auditoría; su reserva sigue en los análisis de demanda y atención. Las preguntas vacías no se rellenan con cero. La fecha de inicio de la reserva ubica el evento en el tiempo, pero no demuestra cuándo se contestó la encuesta. **Calidad necesaria:** vínculos completos y únicos, separación entre el estado de la reserva y el de la encuesta, calificación dentro del dominio observado, disponibilidad por período, conciliación de atributos repetidos y conocimiento de las escalas y formularios históricos. Además, un resultado de satisfacción no demuestra mejora del aprendizaje ni que una modalidad cause mejores resultados.

La encuesta incluye también preguntas sobre cómo se usó el tiempo de la tutoría y sugerencias o reclamos en texto libre, que quedan disponibles en el modelo para los análisis de texto.

Cuidado con la interpretación. La encuesta es voluntaria: los resultados describen a quienes respondieron, no a todos los estudiantes que recibieron una tutoría. Además, la calificación mide la percepción del estudiante, no la calidad objetiva de la tutoría.

1.6. Caracterización general de los datos

El paquete que entregó la coordinación contiene **114 archivos de Excel**, uno por grupo de datos y período, en cinco grupos, con **146.952 filas** en total. Un **período** es un semestre académico y se identifica con un código de seis cifras: el año seguido de 10 (primer semestre), 20 (segundo semestre) o 19 (intersemestral, el curso corto entre semestres). Por ejemplo, 202610 es el primer semestre de 2026.

Fuente	Archivos	Filas	Variables	Una fila representa
Reservas	29	86.562	17	Un evento de reserva
Encuesta Reserva Express (previa)	14	13.815	22	Encuesta previa de una reserva Express
Encuesta Reserva Normal IP (previa)	13	23.437	22	Encuesta previa de una reserva Normal de IP
Encuesta Express (satisfacción)	29	6.759	33	Encuesta posterior de una reserva Express
Encuesta Normal (satisfacción)	29	16.379	35	Encuesta posterior de una reserva Normal
Total	114	146.952		

1.7. Información disponible y relaciones entre las fuentes

Las encuestas reutilizan el ID de la reserva, así que la unidad de trabajo del proyecto es el **evento de reserva: 86.562 registros**, dentro del rango de 80.000 a 200.000 que pide la guía. Además de los datos en tablas hay texto libre: 17.987 comentarios sobre el tutor y la tutoría, que se analizarán en las siguientes entregas.

Los identificadores (ID, códigos) se tratan como texto, no son medidas para promediar. Cada reserva tiene cero o alguna respuesta en cada una de las cuatro encuestas; las respuestas previas y posteriores pueden pertenecer a la misma reserva y se conservan como registros asociados, no como reservas nuevas. Todas las encuestas encuentran su reserva por ID y por ID más período:

Encuesta	Filas	ID con reserva	Sin reserva
Satisfacción Express	6.759	6.759	0
Satisfacción Normal	16.379	16.379	0
Previa Express	13.815	13.815	0
Previa Normal IP	23.437	23.437	0

Cobertura temporal. Las reservas cubren del 19 de agosto de 2016 al 22 de mayo de 2026. Las encuestas previas existen desde el 21 de octubre de 2019. La calificación numérica del tutor tiene respuestas desde el período 201819, y las preguntas de comprensión y de uso de IA aparecen en períodos distintos según la encuesta. El detalle por período está en los Anexos C.2 y C.5.

Limitaciones de los datos. No hay oferta ni capacidad general de franjas, fin efectivo de la sesión, respuestas del tutor como fuente separada, ni versiones certificadas del cuestionario. No se publican

ocupación, cupos libres ni demanda insatisfecha. Tampoco hay notas académicas ni medidas objetivas de aprendizaje, costos o ingresos, de modo que los datos no permiten medir impacto causal en el aprendizaje, rentabilidad ni uso de capacidad. Para incorporar la oferta harían falta registros de franjas ofrecidas, capacidad, recursos y cambios de disponibilidad, con fechas y claves compatibles; su granularidad sería distinta de la de reserva y el modelo no fabrica esos eventos.

2. Ecosistema de analítica

Un **ecosistema de analítica** es el conjunto de herramientas y pasos que llevan los datos desde donde se generan hasta la persona que los consulta: dónde se guardan, cómo se limpian, cómo se organizan y cómo se muestran.

CupiTaller no tiene uno: hoy la coordinación descarga de Bookeau un archivo de Excel por período y lo revisa a mano. Proponemos una arquitectura **Lakehouse por capas**. Un *lakehouse* guarda los datos en archivos baratos y flexibles (como un «lago» de datos) y les añade la organización y las garantías de una base de datos. Los datos pasan por tres capas, llamadas **medallion** (medalla) por su orden de calidad creciente: **Bronze** (bronce), **Silver** (plata) y **Gold** (oro).




Figura 1: Ecosistema de analítica propuesto

Componente	Función	Por qué
Bookeau + exportación	Origen de los datos; la coordinación descarga un Excel por período con todos los servicios y modalidades.	Es el único mecanismo de extracción disponible; no hay acceso directo a la base de datos de Bookeau.
Bronze	Guarda los archivos originales sin modificar (un ZIP con los 114 Excel).	Permite volver a empezar desde cero y rastrear cualquier cifra hasta la celda de origen.

Componente	Función	Por qué
Silver	Un archivo CSV (texto con columnas separadas por comas) por fuente, ya limpio: nombres de columna iguales entre fuentes, fechas en formato estándar (ISO 8601, año-mes-día), tipos de dato explícitos, programa académico normalizado, reglas de negocio aplicadas y banderas (columnas que marcan filas sospechosas).	La limpieza se hace una sola vez y todos los análisis la reutilizan. No se borra ningún registro.
Gold	La base de datos final, organizada como modelo dimensional (sección 4): 3 tablas de hechos y 8 de dimensiones, en SQLite, con restricciones de integridad.	Responde los dos análisis con las mismas categorías para ambos y sin contar dos veces un mismo evento.
Consumo	Un tablero en HTML (un archivo que se abre en el navegador, sin servidor) y consultas en SQL (el lenguaje estándar para consultar bases de datos).	La coordinación puede abrirlo directamente, sin instalar nada.
Calidad y metadatos	Diccionarios (qué significa cada columna), reglas de negocio, bitácora de transformaciones y conciliación entre capas (comparar cuántos registros entran y salen).	Cada decisión queda documentada y se puede verificar.

Qué intervenimos. Trabajamos sobre Bronze (carga e inventario), Silver (limpieza y reglas), Gold (modelo y carga), el consumo (tablero) y la capa de calidad. La oferta de franjas y la capacidad de monitores no se exportan de Bookeau; quedan como fuente futura (línea punteada en la figura).

Para esta entrega la implementación es local, con programas en Python, archivos CSV y la base de datos SQLite (un motor de base de datos contenido en un solo archivo). Los criterios de diseño no dependen de la plataforma, así que se pueden llevar a un lakehouse administrado en la nube (por ejemplo, con el formato Delta Lake) sin cambiar el modelo.

Componentes que se intervienen y cómo. Bronze contiene las 114 hojas originales. Silver conserva los 146.952 registros. Gold conserva las reservas de tutorías (regla R03) y excluye las encuestas inválidas (regla R02). Las respuestas de texto se guardan con su vínculo a la pregunta y a la encuesta para las siguientes entregas. La implementación actual no está conectada a Bookeau ni desplegada en la nube, y no se declara que exista un lakehouse corporativo. Una migración a otra plataforma debe mantener las granularidades, las reglas, las restricciones y la conciliación; formatos, catálogo, acceso, orquestación y carga incremental se decidirían según esa plataforma.

Oferta y capacidad. Los eventos exportados no permiten reconstruir todas las franjas ofrecidas ni los cupos sin reservas. Por eso el primer análisis se limita a patrones de reservas y atención registrada, y no se publican ocupación, cupos libres, duración efectiva ni demanda insatisfecha como magnitudes observadas. Para incorporar la oferta se necesitarían registros de franjas ofrecidas, capacidad, recursos y cambios de disponibilidad, con granularidad propia.

2.1. Pertinencia del ecosistema

Criterio de buena práctica	Cómo lo cumple la propuesta
Separación por capas	Bronze conserva el original, Silver limpia sin borrar y Gold sirve el modelo. Cada capa tiene un solo propósito.
Reproducibilidad y trazabilidad	Cada paso es un programa guardado; cada registro de Gold conserva el archivo, la hoja y la fila de Excel de donde vino.
Metadatos y calidad en todas las capas	Diccionarios, reglas, bitácora y conciliación acompañan los datos.
Proporcionalidad	Con 86.562 reservas y unas 385.000 respuestas, un motor local basta. No se propone un orquestador (programa que lanza y vigila los pasos en secuencia) ni un almacén en la nube que el volumen no justifica.
Capacidad de evolución	El modelo no depende de la plataforma; la oferta de franjas y el texto son extensiones previstas.

3. Exploración y calidad de datos

Revisamos los 114 archivos completos, sin tomar muestras. Las estadísticas de esta sección describen todas las reservas recibidas, antes de aplicar la regla R03. Las tablas completas de este perfilamiento están en el Anexo C.

3.1. Estadísticas descriptivas

Variable (Reservas)	Resultado
Rango de inicio programado	19 de agosto de 2016 a 22 de mayo de 2026, 29 periodos
Duración programada	mínimo 20, mediana 50, máximo 120 minutos
Estados	12 etiquetas: Finalizada 38.541 · Cancelada a tiempo 18.147 · En cola 10.215 · No asistió 5.086 · Cola cancelada por reservación 4.603 · Realizada 4.105 · otras 5.865
Servicios (el curso para el que se pide la tutoría)	11: IP 53.272 · APO 1 (histórico) 21.136 · EDA 6.127 · APO 2 3.922 · otros 2.105
Modalidades (tipo de horario)	10: Normal 49.472 · Express 25.754 · Normal pico 8.668 · otras 2.668
Cantidad de valores distintos	9.943 códigos de usuario · 742 prestadores (monitores) · 213 etiquetas de programa académico
Hora de inicio más frecuente	11:00 (13.699), 14:00 (11.253), 09:00 (10.217)

Calificación del tutor (encuestas válidas)	1	2	3	4	5	Sin nota
Encuestas	122	152	648	2.031	13.218	6.803
% sobre calificadas	0,8 %	0,9 %	4,0 %	12,6 %	81,7 %	—

3.2. Completitud

La **completitud** mide los datos faltantes: dónde están, cuántos registros son y qué porcentaje representan.

Fuente	Variable	Faltantes	%	Interpretación
Todas	Fecha de devolución	146.952	100 %	El campo no se usa; no hay hora real de fin. No se puede medir la duración efectiva de la tutoría.
Reservas	Fecha de llegada	43.422	50,2 %	Esperado: las cancelaciones y la cola no tienen llegada. Ver 3.4.
Reservas	Prestador del servicio (monitor)	42.616	49,2 %	Esperado: solo las citas atendidas tienen monitor asignado.
Reservas	Programa académico	333	0,4 %	Faltante real; se carga como «No informado».
Encuesta Express	Calificación del tutor	1.776	26,3 %	La pregunta no existía antes del período 201819.
Encuesta Normal	Calificación del tutor	5.053	30,9 %	Igual que la anterior.
Encuestas de satisfacción	Comprensión del tema / material del curso	16.786	72–73 %	Preguntas añadidas en períodos recientes.
Encuestas de satisfacción	Comentario sobre tutor y tutoría	5.151	19–23 %	Texto opcional.

Los faltantes de llegada y de prestador dependen del estado de la cita, así que no los tratamos como errores. Los de las encuestas se explican por **cambios del formulario en el tiempo**: la cobertura de cada pregunta por período (primer período con valores) está en el Anexo C.5.

3.3. Unicidad

La **unicidad** revisa que no haya registros repetidos, ni completos ni en lo que los identifica.

Comprobación	Resultado
Filas idénticas en todas las columnas, en cada fuente	0
ID repetido dentro de cada fuente	0 (86.562 ID únicos en Reservas)
ID + período repetido	0
Encuestas sin reserva correspondiente	0 de 60.390 (todas se vinculan por ID y período)
Más de una encuesta del mismo tipo por reserva	0
Repeticiones de significado: variantes de escritura del programa académico	213 etiquetas → 174 tras normalizar mayúsculas, tildes y espacios (Anexo C.11)

La clave de negocio (el ID de la reserva) es única, lo que permite usarla para vincular reservas y encuestas.

3.4. Consistencia

La **consistencia** revisa que los datos sean coherentes entre sí y estén escritos de forma uniforme. El detalle por variable y encuesta está en el Anexo C.7, y el cruce entre estados y llegada en el Anexo C.4.

Comprobación	Casos	%	Tratamiento
Estado cancelado con marca de llegada	32	0,04 %	Se marca con una bandera para revisión
Estado Finalizada sin marca de llegada	8	0,01 %	Bandera
No asistió con marca de llegada	9	0,18 % de No asistió	Bandera
El estado de la reserva difiere entre el archivo de reservas y el de la encuesta	73	0,1 %	Gold usa el valor del archivo de reservas; la diferencia queda guardada
El monitor difiere entre reserva y encuesta	550	1,0–1,6 %	Igual que la anterior
El programa académico difiere entre reserva y encuesta	97	0,1–0,2 %	Igual que la anterior
Encabezado escrito de dos formas («Código servicio» y «Código del servicio»)	4 fuentes	—	Se unifica el nombre de columna en Silver
El grupo de archivo no coincide con la modalidad registrada	1.609 encuestas	—	El archivo <i>Encuesta Normal</i> contiene 1.461 encuestas de «Normal pico»; se segmenta por la modalidad de la reserva
Etiquetas marcadas Deprecated (obsoletas) en el origen	6 servicios y 5 modalidades	—	Se conservan como categorías propias, sin unir las con otras

3.5. Validez

La **validez** revisa que el valor de cada dato tenga sentido en el contexto del problema. Las reglas evaluadas en cada fuente están en el Anexo C.8.

Regla	Evaluables	Incumplen
Fin programado $\geq$ inicio programado	146.952	0
El año del inicio coincide con el año del código de período	146.952	0
Calificación del tutor entre 1 y 5	16.309	0
Llegada más de 1 hora antes del inicio	43.140	37
Llegada después del fin programado	43.140	45
Citas pasadas que siguen en estado no terminal («En ejecución» o «Reservada»)	508	508
Encuestas marcadas «Inválida» por Bookeau	60.390	166

Las 508 citas que siguen «En ejecución» o «Reservada» después de su fecha nunca se cerraron. No se pueden clasificar como atendidas ni como no asistidas, así que quedan fuera de la tasa de inasistencia.

3.6. Transformaciones que se derivan del análisis de calidad

El análisis anterior define qué debe corregirse al pasar los datos de una capa a otra:

1. Unificar nombres de columna, escribir las fechas en formato ISO 8601 y fijar los tipos de dato, tratando los identificadores como texto.

2. Normalizar la escritura del programa académico en una columna adicional, conservando el original.
3. **Regla R01** (Coordinación de Cupitaller): los estados «Finalizada» y «Realizada» se tratan como un solo estado analítico, *Atendida*, y se conserva el estado original.
4. **Regla R02** (Sugerida por el equipo, aprobada por la coordinación): excluir de los análisis las 166 encuestas «Inválida» (marcadas así por Bookeau), pero mantenerlas en Silver para auditoría.
5. **Regla R03** (Coordinación de Cupitaller): la población de Reservas incluye modalidades distintas de la tutoría (entrevistas, salas y etiquetas históricas); para los análisis de Gold solo se incluyen los ID asociados a reservas de tutorías, es decir, las de tipo de horario Normal, Express o Normal pico. Las demás reservas, y las encuestas que les corresponden, permanecen en Silver.
6. **Regla R04** (Coordinación de Cupitaller): una solicitud en cola no ocupa cupo, así que la inasistencia se mide solo sobre citas que llegaron a su hora (Atendida + No asistió). Se guarda como el atributo `grupo_estado` de la dimensión Estado (ver 4.4).
7. Marcar con banderas los casos inconsistentes, sin corregirlos ni borrarlos.
8. No inventar valores: no se rellenan la fecha de devolución, la llegada ni las calificaciones faltantes.

4. Modelo de datos conceptual

Para organizar los datos usamos el **modelo dimensional** de Ralph Kimball, una forma estándar de diseñar bases de datos pensadas para analizar. Se basa en dos tipos de tablas:

- **Tabla de hechos:** registra un evento que se quiere contar o medir. Aquí, una reserva o una encuesta respondida.
- **Tabla de dimensión:** describe el contexto del evento y sirve para filtrar y agrupar. Aquí, la fecha, el servicio, la modalidad, el estado y el programa.

La **granularidad** (en inglés, *grain*) dice qué representa exactamente una fila de una tabla de hechos. Definirla primero evita contar dos veces. Kimball propone cuatro pasos de diseño: elegir el proceso de negocio, definir la granularidad, identificar las dimensiones e identificar los hechos.

4.1. Procesos de negocio y granularidad

Paso	Proceso 1 · Reserva de tutoría	Proceso 2 · Encuesta de la tutoría
1. Proceso de negocio	Solicitud y cierre de una cita en Bookeau	Respuesta del estudiante a la encuesta previa o posterior
2. Granularidad	Un evento de reserva (identificado por el ID de Bookeau)	Una encuesta válida de una reserva; en el detalle, una respuesta no vacía a una pregunta
3. Dimensiones	Fecha (de inicio, de fin y de llegada, con el período académico como atributo), Hora, Servicio, Modalidad, Estado, Programa	Las mismas, compartidas con la reserva, más Tipo de encuesta; el detalle añade Pregunta

Paso	Proceso 1 · Reserva de tutoría	Proceso 2 · Encuesta de la tutoría
4. Hechos (medidas)	evento_reserva (siempre 1, para poder sumar), minutos_programados, es_prioritaria	respuesta_encuesta (siempre 1), calificacion_ayuda_tutor (1 a 5, puede estar vacía); el detalle tiene valor_original y valor_numerico

4.2. Modelos dimensionales propuestos

Cada figura muestra una tabla de hechos al centro y las dimensiones alrededor. Esta disposición se llama *esquema en estrella*.

Modelo 1 · Reservas (responde al Análisis 1)




Figura 2: Modelo dimensional de reservas

Modelo 2 · Encuestas y respuestas (responde al Análisis 2 y prepara el análisis de texto)




Figura 3: Modelo dimensional de encuestas y respuestas

Dimensiones del modelo.

Dimensión	Granularidad y atributos	Motivo
Fecha	Un día del calendario completo; año, mes, día ISO, nombre del día y del mes, indicador de fin de semana, y período académico (código, año del código, terminación y tipo de período)	Permite series y mostrar fechas sin eventos; cumple tres roles (inicio, fin, llegada). El período es un atributo de la fecha: cada día pertenece a un solo período, y los días entre periodos quedan como «Entre períodos»
Hora	Un minuto del día (1.440 miembros)	Segmenta el inicio programado sin confundirlo con los segundos de la llegada
Servicio	Código y etiqueta original	Conserva los catálogos históricos sin fusionar los Deprecated
Modalidad	Tipo de horario y categoría originales	Evita confundir la modalidad con el recurso, y los grupos de archivo con modalidades
Estado	Etiqueta original, estado analítico (R01) y grupo (R04)	Conserva la evidencia y permite contar atenciones sin perder el detalle
Programa	Etiqueta normalizada; miembro 0 «No informado»	Agrupar variantes de escritura y mantiene explícitos los faltantes
Tipo de encuesta	Grupo de fuente y etapa (previa o posterior)	Define el proceso de encuesta; por sí solo no identifica la modalidad real
Pregunta	Texto completo, columna de origen y marcas de texto libre y de calificación	Admite preguntas largas sin un hecho distinto por pregunta

Los atributos de segmentación de la encuesta se toman de la reserva vinculada, como referencia de trabajo acordada; las diferencias del registro de la encuesta permanecen en Silver y en la auditoría de Gold. No se reconstruyen cambios históricos de atributos que las fuentes no traen. Tampoco se crea una dimensión de personas basada solo en nombres. Usuario y prestador permanecen en Silver. Los

programas son etiquetas registradas, no una certificación del programa oficial del estudiante.

El hecho de encuesta incluye las etapas previa y posterior; para la satisfacción se filtra la etapa posterior, y las respuestas previas no se mezclan con las calificaciones del tutor. Una pregunta vacía no genera un hecho de respuesta, pero la encuesta permanece, lo que permite calcular la completitud de cada ítem. Las referencias de fecha de la encuesta describen la reserva asociada, no el momento de contestación.

4.3. Matriz de bus

La **matriz de bus** indica qué dimensiones usa cada tabla de hechos. Una dimensión que usan varias tablas se llama *conformada*: significa lo mismo en todas, y por eso un filtro del tablero sirve para ambos análisis.

Dimensión	Reserva	Encuesta	Respuesta
Fecha, con período (tres roles)	✓ inicio · fin · llegada	✓ inicio de la reserva	vía encuesta
Hora	✓	✓	vía encuesta
Servicio	✓	✓	vía encuesta
Modalidad	✓	✓	vía encuesta
Estado (de la reserva)	✓	✓	vía encuesta
Programa	✓	✓	vía encuesta
Tipo de encuesta		✓	vía encuesta
Pregunta			✓

Medidas y aditividad. Los conteos unitarios son aditivos dentro de su granularidad. Los minutos programados son aditivos como tiempo reservado, pero pueden superponerse entre recursos o usuarios y no equivalen a horas trabajadas ni a ocupación. La calificación no se suma: se calcula su media y mediana con las respuestas no vacías, mostrando el tamaño del grupo. Los porcentajes se recalculan a partir del numerador y el denominador, nunca se suman ni se promedian sin ponderar. Para comparar hechos se agrega primero por las dimensiones compartidas, sin unir filas de preguntas a reservas, para evitar multiplicar conteos.

4.4. Decisiones de diseño y su justificación

Decisión	Justificación
Dos procesos, tres tablas de hechos	Reserva y encuesta tienen granularidades distintas. Mezclarlas en una sola tabla repetiría la reserva por cada encuesta, y contar filas daría más eventos de los reales (146.952 en vez de 86.562).
hecho_reserva es una tabla de hechos sin medidas numéricas propias (<i>factless</i>)	El proceso solo registra que un evento ocurrió; las preguntas se responden contando filas por estado. La columna <code>evento_reserva = 1</code> hace explícita esa cuenta.

Decisión	Justificación
hecho_respuesta es un detalle con dimensión Pregunta	Hay 22 preguntas que cambian según el período y el grupo. Una columna por pregunta dejaría la tabla llena de vacíos y obligaría a cambiar la estructura con cada formulario nuevo. Con la dimensión Pregunta, un formulario nuevo solo agrega filas. Los textos libres quedan listos para la Entrega 2.
id_reserva como dimensión degenerada	Es un identificador que no tiene atributos propios, así que no necesita tabla de dimensión: se guarda en la tabla de hechos. Permite rastrear y vincular reserva y encuesta. En Gold se protege con una clave foránea (ver 4.5).
Fecha con roles (inicio, fin, llegada)	Una sola tabla de calendario sirve tres significados y permite mostrar días sin eventos.
Dimensiones conformadas entre reserva y encuesta	La encuesta toma servicio, modalidad, estado y programa de su reserva. Así un mismo filtro del tablero se aplica a ambos análisis.
Modalidad = tipo de horario + categoría	Es una dimensión pequeña (24 combinaciones) que evita tener dos dimensiones casi vacías.
Estado con jerarquía: original → analítico → grupo	Las reglas de negocio viven en la dimensión, no en cada consulta: estado_analitico aplica la regla R01 y grupo_estado aplica la regla R04 (Atendida, No asistió, Cola, Cancelada, Abierta). Si la coordinación cambia una regla, se modifica una fila de la dimensión y ninguna consulta.
Manejo de cambios en el tiempo (SCD)	Servicio, Modalidad y Estado son tipo 0; Programa es tipo 1. La justificación completa está en 4.6.
Sin dimensión de oferta	La fuente no exporta las franjas ofrecidas ni la capacidad; el modelo no las inventa.
Sin dimensión de personas	Los análisis no la necesitan, y así se evita exponer datos personales de estudiantes y monitores.

Jerarquías y atributos de agrupación. Una **jerarquía** es una cadena de niveles que permite pasar del detalle al resumen y viceversa (en inglés, *drill-down*). Todas están guardadas en Gold:

Dimensión	Jerarquía	Atributos descriptivos
Fecha	día → mes → año	nombre_dia, nombre_mes, dia_semana_iso, es_fin_de_semana
Hora	minuto → hora → franja (Madrugada, Mañana, Tarde, Noche)	etiqueta (HH:MM)
Fecha (período académico)	período → tipo de período (Semestre 1 = terminación 10, Semestre 2 = 20, Intersemestral = 19); los días entre períodos son «Entre períodos»	periodo_original, anio_periodo, sufijo_periodo, tipo_periodo
Estado	estado original (12) → estado analítico (11) → grupo (5)	—
Servicio, Modalidad, Programa	sin jerarquía (listas planas)	código, etiqueta original, categoría

4.5. Criterios de calidad del modelo

Para decidir si el modelo es bueno usamos los siguientes criterios, cada uno con una forma concreta de comprobarlo.

Criterio	Cómo se verifica	Resultado
Granularidad declarada y única	Clave primaria (PK, el identificador único de cada fila) en cada hecho, y restricción de unicidad <code>UNIQUE(id_reserva, tipo_encuesta)</code>	0 violaciones
Integridad referencial (ninguna fila apunta a algo que no existe)	Claves foráneas (FK, referencias de una tabla a otra) activas en SQLite y la verificación <code>PRAGMA foreign_key_check</code>	0 filas huérfanas
Conservación (no se pierde ni se inventa nada)	Los registros de Silver son iguales a los de Gold más las exclusiones documentadas, por fuente	$86.562 = 86.562$; las encuestas concilian (sección 5.3)
Suma correcta de medidas	Las medidas sumables son conteos por fila; las calificaciones solo se promedian; los porcentajes se recalculan a partir de numerador y denominador, nunca se promedian porcentajes	Revisado en las consultas del tablero
Sin vacíos en las claves de dimensión	Categoría «No informado» (clave 0) en Programa	333 reservas apuntan a la clave 0
Valores permitidos en los atributos de agrupación	Restricciones <code>CHECK</code> (la base rechaza valores fuera de una lista o rango) sobre <code>grupo_estado</code> , <code>franja</code> y <code>es_fin_de_semana</code>	0 violaciones
Aptitud para las preguntas	Cada pregunta de 1.4 y 1.5 se responde con una agrupación (<code>GROUP BY</code>) sobre una sola tabla de hechos y sus dimensiones	Ver las consultas en el Anexo C.13
Trazabilidad	Cada hecho conserva el archivo, la hoja y la fila de Excel de origen	100 % de las filas

Estos criterios sirven para comprobar la estructura y la conservación de los datos en esta entrega, pero no sustituyen la confirmación de formularios históricos, de la identidad de los participantes ni de los estados operativos desconocidos. Bastan para esta entrega porque cubren los tres fallos típicos de un modelo dimensional: granularidad mal definida (se cuentan eventos de más), integridad rota (filas que desaparecen al cruzar tablas) y medidas mal agregadas (promedios de promedios). Además, cada criterio se verifica automáticamente en cada carga. La validez de los significados de los estados depende de reglas de negocio, y las que faltan se listan en 5.4.

4.6. Historia de atributos (SCD)

Los atributos de una dimensión pueden cambiar con el tiempo (por ejemplo, un servicio cambia de nombre). Las **dimensiones de cambio lento** (SCD, por *slowly changing dimensions*) son las estrategias para decidir qué se hace con ese cambio:

- **Tipo 0:** el valor no cambia nunca; se guarda tal como se registró.
- **Tipo 1:** se sobrescribe el valor viejo; no queda historia.
- **Tipo 2:** se agrega una fila nueva con fechas de vigencia; se conserva la historia completa.

Dimensión	Tipo	Justificación frente al análisis
Servicio	Tipo 0	El Análisis 2 compara períodos y la transición de APO a IP es un hallazgo en sí. Sobrescribir o unir etiquetas ocultaría ese cambio. Las etiquetas Deprecated se conservan como categorías propias.
Modalidad	Tipo 0	Igual que Servicio: Normal, Express y Normal pico son políticas distintas y su historia se lee en cada reserva.
Estado	Tipo 0 (con reglas versionadas)	El estado de una reserva es un hecho ocurrido, no un atributo que cambie. Las reglas R01 y R04 viven como atributos de la dimensión; si cambian, se documenta la versión y se vuelve a cargar.
Programa	Tipo 1	Las variantes de escritura son errores, no cambios reales (213 etiquetas pasan a 174 al normalizar). Corregir sobrescribiendo es lo correcto.
Fecha (incluido el período), Hora	Estáticas	Son calendarios; no cambian.
Persona (no modelada)	Tipo 2, si se agregara	Solo un cambio real de programa del estudiante justificaría una fila nueva con vigencia. Hoy no se modela porque ningún análisis lo requiere.

Se elige tipo 0 en lugar de tipo 2 porque la fuente no registra cuándo cambió un catálogo: no hay fechas de vigencia que sustenten un tipo 2. Como cada reserva ya trae la etiqueta vigente al momento del evento, el tipo 0 conserva la historia sin inventarla. Si la coordinación exportara una tabla de equivalencias con fechas (ver 5.4), Servicio y Modalidad pasarían a tipo 2.

4.7. Diseño del repositorio

El **repositorio** es el lugar y la forma en que se guardan los datos de Gold. Se compararon cuatro alternativas con los criterios de la primera columna. La evaluación (Alta, Media, Baja) es cualitativa y se basa en el volumen y el uso reales: 86.562 reservas, 60.224 encuestas y 384.792 respuestas, consultadas por una coordinación sin equipo técnico.

- **Relacional (SQLite, esquema en estrella):** tablas con filas y columnas, relacionadas por claves, consultadas con SQL.
- **Columnar (Parquet y DuckDB):** guarda cada columna por separado, lo que acelera los cálculos sobre muchas filas. Parquet es el formato de archivo y DuckDB el motor de consulta.
- **Tabla ancha desnormalizada (CSV):** un solo archivo grande donde cada fila repite todos los atributos de contexto.
- **Documental (JSON):** cada registro es un documento con campos anidados.

Criterio	Relacional (SQLite, en estrella)	Columnar (Parquet y DuckDB)	Tabla ancha (CSV)	Documental (JSON)
Rendimiento analítico con este volumen	Alta: con índices, cientos de miles de filas se agrupan sin problema	Alta: lectura por columna, la mejor a gran escala	Media: hay que recorrer todo el archivo	Baja: agregar exige recorrer documentos
Escalabilidad	Media: un solo archivo y un solo escritor a la vez	Alta: crece por archivos y particiones	Baja	Media
Integridad (PK, FK, CHECK)	Alta: se declara y se verifica al cargar	Baja: sin restricciones declarativas	Baja	Baja
Facilidad de consulta	Alta: SQL estándar y cruces entre dimensiones compartidas	Alta: SQL, pero con herramientas menos conocidas	Media: sin dimensiones, los atributos se repiten	Baja
Almacenamiento	Media: guarda filas completas	Alta: comprime por columna	Baja: repite atributos en cada fila	Baja
Compatibilidad con herramientas de BI (software de tableros)	Alta: se conecta con las herramientas habituales	Media: requiere conector o motor	Media: se importa, pero sin modelo	Baja
Costo y operación	Alta: sin servidor ni licencia	Alta: sin servidor	Alta	Media
Soporte del modelo dimensional	Alta: un hecho por tabla y dimensiones compartidas	Alta: igual, con tablas en archivos	Baja: no distingue hechos de dimensiones	Baja

Recomendación. Para esta entrega, **relacional con esquema en estrella en SQLite**. Es el único con integridad referencial declarativa, que es el criterio central de calidad del modelo (4.5), y con este volumen su rendimiento sobra. Además, un archivo único se entrega sin infraestructura.

Cuándo cambiar. Si el volumen crece unas cien veces (por ejemplo, al incorporar la oferta de franjas por hora) o si se conecta una herramienta de BI con varios usuarios, conviene migrar a almacenamiento columnar (Parquet con DuckDB, o un almacén administrado). El modelo dimensional no cambia, solo el motor.

5. Transformación Silver → Gold

Silver contiene los datos limpios, tal como salen de la fuente pero con formato uniforme. **Gold** contiene los mismos datos reorganizados en el modelo dimensional de la sección 4. Esta sección describe el proceso que convierte uno en otro.

5.1. Entradas y reglas de la transformación

Se leen los cinco archivos CSV de Silver, producto de la limpieza descrita en el Anexo C.11 (nombres comunes, fechas ISO, identificadores como texto, programa normalizado, banderas y trazabilidad). De las reservas solo entran las de tutorías (regla R03); todas las demás permanecen en Silver. De las encuestas solo entran las que tienen `incluir_encuesta_en_analisis = true` (regla R02); las marcadas

falsas se excluyen de Gold y permanecen en Silver, y un indicador desconocido requiere revisión y se concilia aparte. La regla R01 llega a `dim_estado` como etiqueta original y etiqueta analítica. No se infiere encuesta completa ni duración efectiva. Los servicios y modalidades históricos se mantienen separados, y la segmentación de la encuesta usa la reserva vinculada, sin afirmar que se reconstruyó la verdad histórica.

5.2. Diseño del proceso

Paso	Entrada (Silver)	Acción	Salida (Gold)
1	5 archivos CSV	Validar que el ID sea único y que cada encuesta se vincule a una reserva y a un período	— (el proceso falla si no se cumple)
2	Fechas de todas las fuentes	Crear un calendario continuo, asignar a cada día su período académico (el de las reservas que empiezan ese día; los días sin reservas toman el período que los rodea) y los 1.440 minutos del día	<code>dim_fecha</code> , <code>dim_hora</code>
3	Archivo de reservas	Extraer las listas de valores distintos, sin equivalencias inventadas, y calcular los atributos de jerarquía (grupo de estado, franja, nombres de día y mes)	<code>dim_servicio</code> , <code>dim_modalidad</code> , <code>dim_estado</code> , <code>dim_programa</code>
4	Encabezados de las encuestas	Identificar el tipo y la etapa de cada encuesta y el texto completo de cada pregunta	<code>dim_tipo_encuesta</code> , <code>dim_pregunta</code>
5	Archivo de reservas	Cargar todas las reservas, con claves sustitutas (números internos que identifican cada fila de una dimensión) y trazabilidad al origen	<code>hecho_reserva</code>
6	4 archivos CSV de encuestas	Cargar solo las encuestas incluidas por la regla R02; las claves de segmentación se toman de su reserva	<code>hecho_encuesta</code>
7	4 archivos CSV de encuestas	Generar una fila por cada pregunta contestada	<code>hecho_respuesta</code>
8	Base de datos temporal	Aplicar restricciones (PK, FK, CHECK), conciliar y publicar	Base de datos SQLite y archivos CSV de Gold

La carga produce 86.562 reservas, 60.224 encuestas incluidas y 384.792 respuestas no vacías; las 166 encuestas inválidas quedan fuera de Gold y dentro de Silver. No se exige igualdad entre el número de respuestas y el de encuestas porque sus granularidades son distintas. La carga reconstruye todo en una base de datos temporal, y solo reemplaza la versión publicada si pasan todos los controles.

5.3. Decisiones importantes

Decisión	Alternativa descartada	Motivo
Todas las reservas de tutorías pasan a Gold, incluidas cola y cancelaciones	Cargar solo las atendidas	El Análisis 1 necesita los estados no atendidos para calcular inasistencia y cola.
Las encuestas «Inválida» no pasan a Gold (regla R02)	Cargarlas con un indicador	Ningún análisis las usa. Siguen en Silver para auditoría.
La encuesta hereda servicio, modalidad, estado y programa de la reserva	Usar los atributos de la propia encuesta	Garantiza dimensiones compartidas; las diferencias (0,1 % a 1,6 %) se guardan en el campo <code>diferencias_con_reserva_json</code> .
Las respuestas vacías no generan fila	Fila con valor vacío	Así la completitud de cada pregunta se calcula exacta: respuestas / encuestas.
Solo la calificación de 1 a 5 recibe valor numérico	Convertir las escalas de acuerdo («totalmente de acuerdo...») a números	Esas escalas cambian entre formularios; convertirlas inventaría una métrica.
Etiquetas <code>Deprecated</code> sin unir con otras	Unir APO 1 con IP	No hay un catálogo oficial de equivalencias; unirlas mezclaría cursos distintos.

5.4. Mecanismo de validación y resultados

El programa de carga aplica en cada ejecución las validaciones siguientes y guarda sus resultados (detalle en el Anexo C.12):

- Conciliación de conteos por fuente:** filas de Silver = filas de Gold + exclusiones por R02 y R03 + pendientes.
- Restricciones declarativas:** PK, UNIQUE, CHECK (valores 0/1, calificación de 1 a 5, duración mayor o igual a cero) y FK, aplicadas al insertar cada fila.
- Verificación posterior:** `PRAGMA foreign_key_check` y comprobación de que cada granularidad es única.
- Conciliación de medidas:** las atenciones (R01) y las exclusiones (R02) se recalculan en Gold y se comparan con Silver.

Fuente	Filas Silver	Encuestas Gold	Excluidas por R02	Respuestas no vacías	Resultado
Reservas	86.562	86.562 (reservas)	—	—	OK
Encuesta Express	6.759	6.706	53	55.720	OK
Encuesta Normal	16.379	16.268	111	180.072	OK
Encuesta Reserva Express	13.815	13.815	0	55.260	OK
Encuesta Reserva Normal	23.437	23.435	2	93.740	OK
IP					
Total encuestas	60.390	60.224	166	384.792	OK

Controles adicionales: las atenciones por R01 son 42.646 tanto en Silver como en Gold; las claves foráneas huérfanas son 0; las granularidades duplicadas son 0.

5.5. Correcciones que debería hacer el responsable de la fuente

Algunos problemas no se pueden arreglar en el análisis; los debe corregir quien administra Bookeau antes de exportar los datos.

Problema	Casos	Corrección sugerida en Bookeau
La fecha de devolución nunca se registra	100 %	Registrar la hora real de cierre de la sesión, o quitar el campo de la exportación.
Citas pasadas sin cerrar («En ejecución», «Reservada»)	508	Cierre automático de estados al terminar el día.
Estado contradictorio con la llegada	49	Validar el estado contra la marca de llegada al cerrar la cita.
Llegada fuera de la ventana de la cita	82	Revisar el reloj o el proceso de registro de llegada.
«Finalizada» y «Realizada» sin definición	42.646	Documentar la diferencia o unificar los estados.
Criterio de encuesta «Inválida» no documentado	166	Exportar el motivo de invalidez.
Etiquetas <code>Deprecated</code> sin catálogo histórico	11 etiquetas	Publicar la tabla de equivalencias entre servicios y modalidades.
Programa académico en texto libre	213 variantes	Usar una lista cerrada de programas.
Preguntas sin identificador ni versión	22	Exportar un ID de pregunta y la versión del formulario.
Oferta de franjas y capacidad	—	Exportar las franjas ofrecidas, para medir la ocupación.

6. Respuesta a los análisis

Las cifras de esta sección se calcularon antes de aplicar la regla R03 y deben recalcularse con la población de tutorías. El tablero (un archivo HTML) funciona sin conexión a internet y permite filtrar por período, servicio y modalidad. Los filtros se aplican a las dos secciones.

6.1. Análisis 1 · Inasistencia y presión de cola




Figura 4: Tablero, sección de reservas

La **tasa de inasistencia** es la parte de las citas en que el estudiante llegó a su hora, o debía haber llegado, y no se presentó. Se calcula como $\text{No asistió} / (\text{Atendida} + \text{No asistió})$.

Modalidad	Eventos	Atendidas	Inasistencia	En cola	Canceladas
Normal	49.472	24.644	8,7 %	19,3 %	25,7 %
Express	25.754	11.798	13,9 %	16,1 %	30,2 %
Normal pico	8.668	4.654	9,0 %	11,8 %	27,8 %
Total (todas)	86.562	42.646	10,7 %	17,1 %	—

Hallazgos:

- **Express tiene una inasistencia 60 % mayor que Normal** (13,9 % frente a 8,7 %). Como la cita es corta y fácil de reservar, el estudiante pierde poco si no llega. Es el primer candidato para recordatorios automáticos o para que la sanción también cuente en Express.
- **La inasistencia crece a lo largo de la semana:** lunes 7,4 %, martes 10,0 %, miércoles 10,9 %, jueves 12,1 %, viernes 12,7 %. Por hora, las franjas de 10:00, 13:00 y 16:00 superan el 11,5 %. Las de 18:00 a 19:00 llegan al 25–32 %, pero tienen pocos eventos.
- **Una de cada seis solicitudes (17,1 %) termina en cola** sin llegar a una cita. Es una señal directa de demanda no atendida, y la más alta es en Normal (19,3 %). La proporción en cola bajó

de entre 14 % y 20 % (2020 a 2024) a 6,9 % en 202610, a la vez que el volumen de reservas cayó de unas 5.000 a 1.970 por semestre. La coordinación debería averiguar la causa de esa caída.

6.2. Análisis 2 · Satisfacción




Figura 5: Tablero, sección de satisfacción

Segmento	Calificadas	Media	Calificaciones 1 a 3
Normal	9.722	4,77	4,7 %
Express	4.878	4,70	6,6 %
Normal pico	1.450	4,62	9,2 %
IP	8.908	4,68	7,2 %
EDA	2.146	4,68	7,9 %
APO 1 (histórico)	4.332	4,85	2,1 %
Total	16.171	4,74	5,7 %

Hallazgos:

- La satisfacción es alta (media 4,74; 81,7 % de cincos). La señal útil está en el 5,7 % de calificaciones de 1 a 3.
- **Normal pico tiene casi el doble de calificaciones bajas que Normal (9,2 % frente a 4,7 %).** Es coherente con una sesión en semana de alta demanda: más carga para el monitor y menos tiempo por estudiante.

- Las calificaciones bajas pasaron de cerca del 2 % (2018 y 2019, APO) a cerca del 7,5 % (2023 a 2025, IP y EDA), con un máximo de 14,9 % en 202210. El cambio coincide con la transición de APO a IP y con cambios en el formulario. No lo atribuimos solo al servicio, pero es el período que la coordinación académica debería revisar primero.
- La completitud de la pregunta de calificación es del 70,4 %. Como la encuesta es voluntaria, los resultados describen a quienes respondieron.

6.3. Por qué el modelo es adecuado para estos análisis

Criterio	Cómo lo cumple el modelo
Cada indicador se calcula sobre una sola tabla de hechos, a la granularidad correcta	Inasistencia y cola: un conteo (COUNT) sobre hecho_reserva agrupado por dim_estado . Calificaciones: hecho_encuesta filtrado a la encuesta posterior. Ningún indicador cruza dos tablas de hechos fila a fila.
Los filtros son coherentes entre los dos análisis	Fecha (con su período), servicio y modalidad son dimensiones compartidas, así que el mismo filtro significa lo mismo en ambas secciones.
Los denominadores son explícitos	Las reglas R01 y R04 son atributos de la dimensión Estado (estado_analitico , grupo_estado) y R02 y R03 son filtros de carga; las consultas solo agrupan por esos atributos. El tablero muestra el número de casos (n) junto a cada porcentaje.
Se puede pasar del resumen al detalle	Las jerarquías permiten ir de tipo de período a período, de franja a hora y de grupo de estado a estado original. Por ejemplo, la proporción en cola es 12,2 % en intersemestrales frente a 16,9–17,5 % en semestres.
El tablero no tiene que corregir problemas de calidad	Las exclusiones e inconsistencias se resuelven en Silver y Gold; el tablero solo suma y agrupa.
El modelo puede crecer	La oferta de franjas se incorporaría como una nueva tabla de hechos con las mismas dimensiones (Fecha, Hora, Servicio, Modalidad); el texto ya está en hecho_respuesta .

6.4. Usuarios y funcionalidad del tablero

Usuario	Análisis	Interacción	Cómo lo soporta el modelo
Coordinación de CupiTaller	1. Inasistencia y cola	Filtra por período, servicio y modalidad; lee las tasas con su número de casos; compara por día de la semana y hora	hecho_reserva con dim_estado (grupo de estado), dim_fecha y dim_hora ; un conteo por estado
Coordinación académica de los cursos	2. Satisfacción	Filtra por los mismos criterios; revisa la proporción de calificaciones de 1 a 3 y su evolución por período	hecho_encuesta filtrado a la encuesta posterior, con dimensiones compartidas

Usuario	Análisis	Interacción	Cómo lo soporta el modelo
Ambos	Exploración	Pasan de tipo de período a período, de franja a hora y de grupo de estado a estado original	Jerarquías guardadas en las dimensiones (4.4)

El tablero es un archivo HTML que no necesita servidor, porque la coordinación no tiene infraestructura de BI. Las decisiones de modelo que lo hacen posible (dimensiones compartidas, reglas guardadas en `dim_estado`, una sola granularidad por tabla de hechos) están justificadas en 4.4 y 6.3.

7. Gestión del proyecto

7.1. Contribuciones y distribución de puntos

Sección por completar por el equipo. No se puede redactar a partir del repositorio: debe reflejar el trabajo real de cada persona.

Integrante	Trabajo realizado	Puntos (de 100)	Justificación
[Nombre 1]	[p. ej., perfilamiento y calidad, punto 3]	[]	[compromiso, calidad, cumplimiento, participación]
[Nombre 2]	[]	[]	[]
[Nombre 3]	[]	[]	[]
[Nombre 4]	[]	[]	[]

Problemas identificados en el equipo: [p. ej., carga concentrada en una persona, reglas de negocio confirmadas tarde]

Estrategias para la Entrega 2: [p. ej., responsables por punto desde el inicio, revisión cruzada antes de entregar, reunión con la coordinación en la primera semana]

7.2. Uso de inteligencia artificial generativa

Uso dado. Usamos un asistente de programación con inteligencia artificial para: escribir los programas que leen los archivos de Excel, perfilan los datos (calculan sus estadísticas), los limpian y cargan Gold; proponer y discutir el modelo dimensional; generar el tablero, las figuras y los borradores de documentación y de este informe; y hacer una clasificación exploratoria de comentarios (fuera del alcance de esta entrega). Las reglas de negocio R01 a R04 son decisiones humanas. Cada cifra del informe se contrastó con las salidas de los programas y de las consultas SQL.

Ventajas para la organización: procesos reproducibles en lugar de revisión manual de Excel; documentación y diccionarios generados junto con el código; capacidad de explorar alternativas de modelo rápidamente.

Riesgos para la organización:

- **Privacidad:** las fuentes contienen nombres, correos y códigos de estudiantes y monitores, y comentarios sobre personas. Pasar estos datos a un servicio de IA externo requiere autorización y anonimización previa.
- **Significados inventados:** la IA puede proponer interpretaciones plausibles pero falsas de estados o campos. Lo mitigamos con reglas confirmadas por personas (R01 a R04) y con banderas en lugar de correcciones automáticas.
- **Exceso de confianza en métricas automáticas:** por ejemplo, un clasificador automático de comentarios que coincide solo en 62 % con una revisión hecha por otra IA no sirve para evaluar a monitores. Por eso lo dejamos fuera del entregable.
- **Dependencia:** el equipo debe entender y poder mantener el código generado.