

DESCRIPCIÓN GENERAL

El proyecto se realiza en el contexto de una organización que requiere realizar proyectos de analítica y de un acompañamiento para generar modelos de datos conceptuales, decidir el modelo o modelos de datos que requiere para almacenar los datos, estructurados según el modelo conceptual planteado y, visualizar el resultado de los análisis identificados. En cada una de las etapas a realizar, se requiere dar una justificación a las propuestas y una serie de recomendaciones si aplica al caso.

El éxito del proyecto depende de los datos que logren conseguir y del apoyo que tengan de los expertos relacionados con los datos y los análisis que se quieren realizar. En caso de que tengan problemas para acceder a datos de la empresa, pueden apoyarse en portales de datos abiertos como datos.gov.co o [kaggle.com](https://www.kaggle.com).

ENTREGA 1

Los puntos solicitados en la primera entrega corresponden a los pasos seguidos con la metodología del grupo Kimball, ajustada a las propuestas modernas de *Data Lake House*. Con el fin de realizar los análisis propuestos. ACME de los Alpes ha contactado a su grupo y ha definido los siguientes entregables para esta primera actividad:

1. **[5 puntos] Definición del objetivo y los análisis requeridos:** En este punto estamos entendiendo la organización y en particular el contexto que requiere los análisis. Es así como deben describir de forma general la empresa y la dependencia o división con la que van a trabajar y, definir al menos dos análisis a resolver. Estos análisis deben ser descritos en términos del objetivo del análisis, rol o función de la persona hacia quien está definido el análisis, descripción de los datos a utilizar y si es posible del proceso que los genera. Esta información debe guiarlos a entender el proceso de negocio relacionado con los análisis y los datos asociados. De estos últimos deben entregar una caracterización general que incluya la cantidad de datos compartidos y la cantidad de variables que los describen.
2. **[5 puntos] Ecosistema de analítica:** En este punto deben graficar y describir el ecosistema de analítica en la empresa. Si no existe, proponer uno con base en lo visto en clase y justificar la propuesta. Adicionalmente, deben definir el o los componentes dentro del ecosistema de analítica de la empresa que van a intervenir, por ejemplo, en la capa *gold*, en la *silver*, e indica qué van a realizar en ese componente.
3. **[8 puntos] Exploración y calidad de datos.** Datos estadísticos de los datos compartidos y análisis de las dimensiones de completitud, unicidad, consistencia y validez. Según la

naturaleza de los datos puede requerir cambiar o incluir dimensiones adicionales de calidad de datos.

La completitud muestra problemas por datos faltantes. En esta dimensión deben indicar en donde se encuentra el problema, la cantidad de registros y el porcentaje que representa. La unicidad analiza si se encuentran registros duplicados ya sea en su totalidad o parcialmente. En este último caso deben validar si hay repeticiones a nivel semántico que no debería estar. Por ejemplo, en una fuente de estudiantes matriculados a un programa, no deberían existir dos registros con el mismo código del estudiante. La consistencia mide la coherencia de los datos y de su representación. En este caso pueden tener variables relacionadas entre ellas, de una misma fuente de datos, las cuales deben ser analizadas de forma conjunta para identificar posibles problemas. En esta dimensión se incluyen problemas de estandarización de los datos, por ejemplo, el caso de diferentes formatos utilizados para una variable fecha. Finalmente, la validez verifica que el valor de los datos tenga sentido en el contexto del problema.

El análisis de la calidad de los datos permite identificar procesos de transformación que deben ser aplicados posteriormente sobre los datos.

4. **[12 puntos] Modelo de datos conceptual.** Según los procesos requeridos para resolver los análisis propuestos, proponer los modelos dimensionales a utilizar, acompañados de su descripción y justificación en términos de calidad. En este punto es importante definir los criterios a utilizar para validar la calidad del modelo e indicar por qué consideran son suficientes.
5. **[12 puntos] Diseño del proceso de transformación o adecuación** requerido entre la capa *Silver* y la *Gold* (o su equivalente), donde se almacenan los datos en la estructura propuesta, a partir de los datos entregados. En este punto se deben incluir las justificaciones asociadas a las decisiones importantes relacionadas con los modelos de datos y los puntos que considera pueden ser corregidos por el responsable de la fuente de datos, antes de ser enviados al sistema de analítica. Defina el mecanismo para validar que la transformación quedo bien y aplique ese mecanismo a su proceso.
6. **[8 puntos] Respuesta a los análisis.** Uso de uno o más tableros de control para responder a los análisis propuestos. Deben incluir la descripción de criterios utilizados para determinar que el modelo de datos propuesto es apropiado para ese estilo de análisis.
7. **Gestión del proyecto**
 - a. Describir el trabajo de cada miembro del equipo y la distribución de 100 puntos entre los integrantes del grupo. Justifiquen su respuesta. Tengan en cuenta: el **compromiso** en el logro de resultados, la **calidad** de la contribución, el cumplimiento de compromisos adquiridos con el grupo y la **participación** equitativa en el trabajo del equipo. Identifique problemas al interior de grupo y diseñe estrategias para mejorar en la siguiente entrega.
 - b. Describir el uso dado a la inteligencia artificial generativa. Indique las ventajas y los riesgos que puede tener este uso en la organización para la que desarrolla el proyecto.

RESTRICCIONES

- * Los datos a trabajar en el proyecto deben incluir datos tabulares y de otros formatos como textos. El formato de texto será utilizado en las siguientes entregas del proyecto.
- * El número de registros esperado para el proyecto está entre los 80.000 y 200.000
- * El proyecto se realiza en grupos de entre 3 y 4 estudiantes
- * La evaluación tiene un componente grupal (75%) y otro individual (25%). La evaluación individual utiliza la respuesta dada al punto 7.